SVEUČILIŠTE U ZAGREBU
FAKULTET ORGANIZACIJE I INFORMATIKE
V A R A Ž D I N

Grgo Lalić

SUSTAV ZA PRAĆENJE I OCJENJIVANJE IGRAČA HRVATSKE NOGOMETNE LIGE (HNL)

Varaždin, 2026.

SVEUČILIŠTE U ZAGREBU

FAKULTET ORGANIZACIJE I INFORMATIKE

V A R A Ž D I N

Grgo Lalić

Kolegij: Baze podataka 2

SUSTAV ZA PRAĆENJE I OCJENJIVANJE IGRAČA HRVATSKE NOGOMETNE LIGE (HNL)

Mentorica:

Maja Cerjan, mag. educ. inf.

Varaždin, siječanj 2026

Grgo Lalić

Izjava o izvornosti

Izjavljujem da je moj završni/diplomski rad izvorni rezultat mojeg rada te da se u izradi istoga nisam koristio drugim izvorima osim onima koji su u njemu navedeni. Za izradu rada su korištene etički prikladne i prihvatljive metode i tehnike rada.

Sadržaj

Uvod 1
Opis aplikacijske domene 2
Popis korištenih tehnologija i alata 2
Draw.io 2
MySQL Community Server i MySQL Workbench 2
Prikaz i razrada ERA modela 3
Prikaz jednostavnih i složenih upita 5
Prikaz jednostavnih upita 5
Prikaz složenih upita 6
Okidači 8
Primjer 1 8
Početna funkcija 8
Prvi trigger 9
Drugi primjer 9
Prikaz funkcionalnosti razvijenog sučelja 10
ZAKLJUČAK 12
Popis literature 13
Popis slika 13

Uvod

U suvremenom nogometu podaci su postali jedan od ključnih temelja odlučivanja – od stručnog stožera i skauta, preko uprava klubova, pa sve do navijača i sportskih analitičara. Hrvatska nogometna liga (HNL) također generira velik broj informacija o učinku igrača na svakoj utakmici (minute, golovi, asistencije, udarci, dodavanja, driblinzi, disciplinske mjere i dr.), a te informacije dobivaju pravu vrijednost tek kada su sustavno prikupljene, povezane i obrađene. Zbog toga je sve važnija izrada informacijskih sustava koji omogućuju pouzdano spremanje podataka te njihovu interpretaciju kroz izvještaje i metrike, pri čemu je ocjena igrača jedan od najpraktičnijih sažetih pokazatelja performansi.

Cilj ovog projekta je izrada sustava za praćenje i ocjenjivanje igrača HNL-a koji objedinjuje podatke o natjecanju, klubovima, igračima, utakmicama i pojedinačnim nastupima, te omogućuje računanje ocjene na temelju zabilježene statistike. Projekt se temelji na standardnom procesu izrade baze podataka: izradi ERA modela, implementaciji modela u MySQL-u te demonstraciji rada kroz upite, okidače i jednostavno sučelje s osnovnim CRUD operacijama.

Poseban naglasak stavljen je na entitet "ocjena" koja je temeljni objekt promatranja ovog rada. Iako su pojedini statistički pokazatelji važni sami po sebi, ocjena predstavlja agregirani rezultat koji olakšava usporedbu igrača kroz različite utakmice. U sustavu se ocjena automatski izračunava iz statistike nastupa te se uz pomoć okidača ažurira pri unosu ili promjeni statističkih podataka, čime se osigurava konzistentnost i smanjuje mogućnost ručnih pogrešaka. Na taj način baza omogućuje i osnovnu analitiku (npr. prosjeke ocjena, rang-liste i preglede po utakmicama), dok sučelje olakšava unos i pregled podataka u svakodnevnom korištenju.

Ključne riječi: baze podataka, ERA model, Hrvatska nogometna liga (HNL), nogometna statistika, ocjenjivanje igrača, relacijski model, SQL upiti, okidači, CRUD operacije, informacijski sustav**.**

Opis aplikacijske domene

Aplikacijska domena ovog projekta odnosi se na informacijski sustav za praćenje i analizu učinka nogometaša u HNL-u. Sustav je namijenjen korisnicima koji se bave analizom nogometnih podataka, poput sportskih analitičara, stručnih stožera klubova, skauta ili sportskih novinara, ali i kao potpora edukacijskim i analitičkim potrebama. Cilj sustava je omogućiti centralizirano prikupljanje podataka o igračima, klubovima i utakmicama te njihovu obradu u obliku preglednih statistika i ocjena.

U okviru aplikacijske domene sustav obuhvaća evidenciju liga i sezona, klubova i stadiona, igrača i njihovih nastupa na utakmicama, kao i detaljnih statističkih pokazatelja svakog nastupa. Na temelju prikupljenih podataka sustav automatski izračunava ocjenu igrača, čime se omogućuje objektivnija procjena individualnog učinka te usporedba igrača unutar iste utakmice, kluba ili sezone. Takav pristup odgovara stvarnim potrebama sportske analitike, gdje je važno brzo i konzistentno vrednovati izvedbu igrača na temelju dostupnih podataka.

Popis korištenih tehnologija i alata

Za izradu ovog projekta korišteni su alati draw.io za izradu ERA modela te MySQL Community server i MySQL Workbench za implementaciju i rad s bazom podataka. Navedeni alati omogućili su cjelovit proces izrade baze podataka, od faze modeliranja do implementacije i testiranja funkcionalnosti kroz SQL upite i okidače

Draw.io

draw.io je web-temeljen alat za izradu dijagrama koji omogućuje jednostavno i pregledno modeliranje različitih vrsta sustava, uključujući ERA dijagrame baza podataka. Alat nudi intuitivno grafičko sučelje u kojem je moguće definirati entitete, atribute, primarne i strane ključeve te veze između entiteta. U ovom projektu draw.io korišten je za izradu ERA modela sustava za praćenje i ocjenjivanje igrača HNL-a, pri čemu je omogućeno jasno vizualno prikazivanje strukture baze podataka prije same implementacije. Prednost alata je njegova dostupnost bez potrebe za instalacijom te mogućnost jednostavnog izvoza dijagrama u slikovne formate.

MySQL Community Server i MySQL Workbench

MySQL Community Server je relacijski sustav za upravljanje bazama podataka otvorenog koda koji se široko koristi u praksi, kako u akademskom okruženju tako i u stvarnim aplikacijama. U ovom projektu MySQL Community Server korišten je kao temeljni sustav za pohranu podataka, definiranje tablica, relacija, ograničenja te izvođenje SQL upita i okidača. Sustav omogućuje stabilan i učinkovit rad s većim količinama podataka te podržava standardni SQL jezik.
Za administraciju i rad s bazom korišten je MySQL Workbench, službeni grafički alat za upravljanje MySQL bazama podataka. MySQL Workbench omogućuje pregledno izvođenje SQL upita, upravljanje tablicama, korisnicima i privilegijama, kao i testiranje okidača i upita. Iako se na vježbama iz kolegija koristi alat DataGrip, koji također nudi napredne mogućnosti rada s bazama podataka, u okviru ovog projekta odabran je MySQL Workbench s ciljem upoznavanja novog alata i rada u okruženju koje se često koristi u stvarnim projektima i industrijskoj praksi. MySQL Workbench jedan je od najraširenijih alata za rad s MySQL bazama podataka u svijetu te predstavlja pouzdano i korisno rješenje za razvoj i administraciju relacijskih baza podataka.

Prikaz i razrada ERA modela

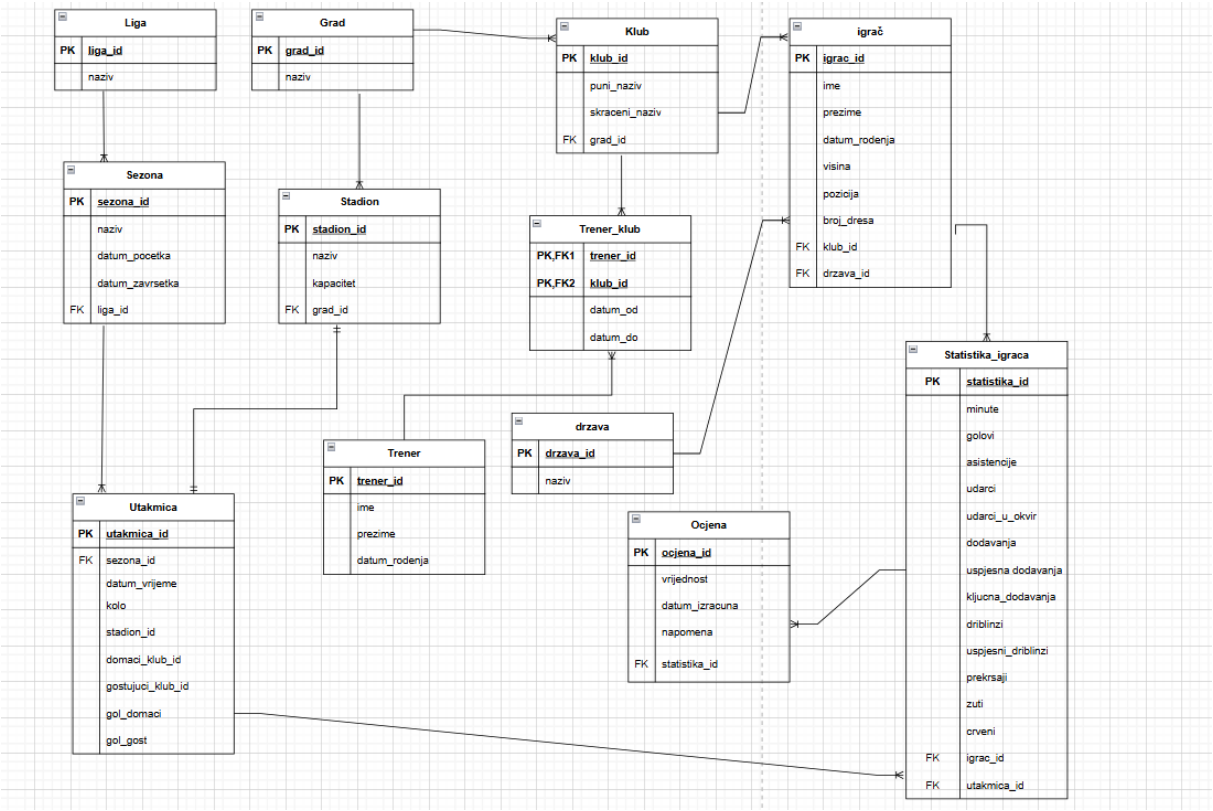

Slika 1 : ERA model, autorski rad

Model je osmišljen tako da pokrije osnovne entitete natjecanja (liga, sezona), infrastrukturu (grad, stadion), sudionike (klub, igrač, trener), događaje (utakmica) te najvažniji dio domene – nastup igrača na utakmici s pripadnom statistikom i automatski izračunatom ocjenom. Fokus modela je na dosljednom povezivanju podataka, očuvanju integriteta (primarni i strani ključevi) te podršci za analitičke upite (rang-liste, prosjeci, pregledi po utakmici ili sezoni).
U vrhu modela nalazi se entitet Liga (liga_id, naziv) koji predstavlja natjecanje, dok entitet Sezona sa svojim atributima omogućuje praćenje različitih sezona unutar lige. Veza između lige i sezone je 1:N – jedna liga može imati više sezona, a svaka sezona pripada točno jednoj ligi. Time se osigurava da se utakmice i statistike mogu grupirati po sezoni, što je ključno za upite poput "najbolji igrač sezone" ili "prosječna ocjena igrača u sezoni".
Za opis lokacija uveden je entitet Grad (grad_id, naziv) koji je povezan s entitetima Klub i Stadion. Entitet Stadion (stadion_id, naziv, kapacitet, grad_id) opisuje stadione na kojima se igraju utakmice, pri čemu svaki stadion pripada jednom gradu (1:N između grada i stadiona). Entitet Klub predstavlja klubove HNL-a - svaki klub je smješten u određenom gradu (1:N veza između grada i klubova). Ovakva struktura omogućuje upite poput "svi klubovi iz određenog grada" ili "sve utakmice na stadionima u određenom gradu".
Središnji događajni entitet je Utakmica sa svojim navedenim atributima. Svaka utakmica pripada jednoj sezoni i igra se na jednom stadionu, što se ostvaruje stranim ključevima prema tablicama Sezona i Stadion. Posebno je važno naglasiti da utakmica ima dva različita odnosa prema entitetu Klub: jedan klub je domaći, drugi gostujući. To sam u ERI rješio tako da sam u tablici utakmica stavio dva strana ključa, domaci_klub_id i gostujuci_klub_id, koji referenciraju klub(klub_id). Time se jasno razlikuju uloge klubova u utakmici, a ujedno se omogućuju analize poput "učinak domaćih utakmica nekog kluba" ili "gol-razlika na gostovanjima".

Entitet Drzava (drzava_id, naziv) služi za evidenciju nacionalnosti igrača (i po potrebi drugih osoba). Entitet Igrac pohranjuje osnovne podatke o igraču te poveznice na klub i državu. U ovom projektu igrač ima atribut klub_id koji predstavlja trenutni klub igrača. Svjesno sam donio odluku da se povijest transfera ne modelira dodatnom veznom tablicom (npr. igrac_klub) jer je fokus sustava na ocjenjivanju nastupa i statistike u okviru natjecanja, a ne na potpunom modeliranju transfernog tržišta. To sam tako postavio radi pojednostavljenja domene zbog jasnije implementacije i lakše demonstracije funkcionalnosti (CRUD, upiti, okidači), pri čemu se i dalje dobiva potpuna slika učinka igrača kroz utakmice i sezone.
S druge strane, entitet Trener (trener_id, ime, prezime, datum_rodenja) te vezna tablica Trener_klub (trener_id, klub_id, datum_od, datum_do) koriste se za praćenje angažmana trenera u klubovima kroz vrijeme. Ovdje je uključena vremenska komponenta (datum od/do) jer je promjena trenera česta i posebno relevantna na razini sezona, a ova struktura omogućuje i upite poput "tko je bio trener kluba u određenom razdoblju". Važno je naglasiti da ovo nije kontradikcija u odnosu na igrača: model za trenera uključuje povijest angažmana jer je taj aspekt često predmet analize, dok se kod igrača vodi trenutni klub jer transferi nisu primarni cilj projekta. Drugim riječima, razina detalja je prilagođena ciljevima sustava.
Najvažniji dio modela koji povezuje cijelu domenu je entitet Statistika_igraca. Ova tablica predstavlja nastup igrača u konkretnoj utakmici. Time se rješava prirodni M:N odnos između igrača i utakmica: jedan igrač može sudjelovati u više utakmica, a jedna utakmica uključuje više igrača. Strani ključevi igrac_id i utakmica_id jednoznačno određuju na koga i na koju utakmicu se statistika odnosi, dok atributi unutar tablice bilježe detaljne metrike nastupa. Ovakvo modeliranje omogućuje izradu gotovo svih tipičnih nogometnih statističkih izvještaja (npr. top strijelci, asistenti, prosječna minutaža, uspješnost dodavanja) te je prirodna osnova za izračun ocjene.
Entitet Ocjena (ocjena_id, vrijednost, datum_izracuna, napomena, statistika_id) uveden je kao zaseban entitet jer je ocjena središnji rezultat sustava i logički "proizvod" obrade statistike. Svaka ocjena povezana je s točno jednom stavkom statistike (statistika_id), čime se ostvaruje veza 1:1 između Statistika_igraca i Ocjena (u praksi se osigurava jedinstvenošću statistika_id u tablici ocjena). Ocjena se ne unosi ručno, nego se automatski generira i ažurira pomoću okidača na temelju promjene statistike (opisano kasnije). Time se postiže konzistentnost: svaka promjena u broju golova, asistencija, uspješnih dodavanja i slično automatski se odražava na ocjenu, bez potrebe za ručnim računanjem. Dodatno, atributi datum_izracuna i napomena omogućuju evidentiranje vremena izračuna i eventualnog komentara/pojašnjenja.
Zaključno, ERA model je izgrađen tako da podrži cjelovit tijek rada: od unosa osnovnih podataka (liga, sezona, klubovi, igrači), preko evidencije utakmica i nastupa, do izračuna ocjene i analitike. Model je normaliziran u mjeri koja omogućuje preglednost i smanjenje redundantnosti, a istovremeno je dovoljno praktičan za implementaciju u MySQL-u i izradu jednostavnog sučelja s CRUD operacijama. Donesene dizajnerske odluke (npr. trenutni klub igrača, povijest angažmana trenera, zaseban entitet ocjena) usklađene su s ciljem projekta: omogućiti pouzdano praćenje nastupa i automatsko, dosljedno ocjenjivanje igrača HNL-a kroz utakmice i sezone.

Prikaz jednostavnih i složenih upita

Prikaz jednostavnih upita

1 . primjer jednostavnog upita koji vraća sav sadržaj iz tablice “igrač”

```
1 •   SELECT * from igrac
```

Result Grid | Filter Rows: | Edit: | Export/Import: | Wra

igrac_id	ime	prezime	datum_rodenja	visina	pozicija	broj_dresa	klub_id	drzava_
1	Bruno	Petković	1994-09-16	193	Napadač	9	1	1
2	Martin	Baturina	2003-02-16	172	Vezni	10	1	1
3	Marko	Livaja	1993-08-26	182	Napadač	10	2	1
4	Filip	Krovinović	1995-08-02	175	Vezni	23	2	1
5	Niko	Janković	2001-02-14	180	Vezni	4	3	1
6	Gabriel	Rukavina	2004-05-01	178	Krilni	11	3	1
7	Ramón	Miérez	1997-05-13	181	Napadač	9	4	5
8	Domagoj	Bukvić	2003-07-19	176	Vezni	20	4	1
9	Matej	Vuk	2000-06-05	185	Napadač	9	5	1
10	Leon	Barišić	2002-03-12	180	Branič	5	5	1
NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL

Result Grid | Form Editor | Field Types | Query Stats

Slika 2 : prvi jednostavan upit, autorski rad

2 . jednostavan upit koji iz tablice klub vraća samo puni i skraćeni naziv kluba

```
1   SELECT puni_naziv, skraceni_naziv
2   FROM klub
3   ORDER BY puni_naziv ASC;
4
```

Result Grid | Filter Rows: | Export: | Wrap Cell Content:

puni_naziv	skraceni_naziv
GNK Dinamo Zagreb	Dinamo
HNK Hajduk Split	Hajduk
HNK Rijeka	Rijeka
NK Osijek	Osijek
NK Varaždin	Varazdin

Result Grid | Form Editor | Field Types | Query Stats

klub 4 × | Read Only

Slika 3 : drugi jednostavan upit, autorski rad

3 . jednostavan upit u kojem možemo vidjeti na koji način se spajaju dvije tablice, u ovom slučaju tablica utakmica i stadion, upit vraća id utakmice, vrijeme i stadion na kojem se utakmica odigrala

```
SELECT u.utakmica_id, u.datum_vrijeme, s.naziv AS stadion
FROM utakmica u
JOIN stadion s ON u.stadion_id = s.stadion_id;
```

utakmica_id	datum_vrijeme	stadion
1	2024-08-10 20:00:00	Maksimir
2	2024-08-11 21:00:00	Poljud
3	2024-08-12 19:00:00	Rujevica

Slika 4 : treći jednostavan upit, autorski rad

Prikaz složenih upita

1 . Primjer složenog upita koji uzima tablice klub, igrac, statistika_igraca, ocjena i utakmica a kao rezultat upita vraća utakmicu, rezultat, vrijeme održavanja utakmice i klub sa prosječnom ocjenom. U liniji „order by proesjecna_ocjena_kluba“ su uzete najbolje ocjene na razini kluba, a limiterom 10 je uzeto top 10 nastupa klubova u sezoni.

```
SELECT
  k.skraceni_naziv AS klub,
  CONCAT(k1.skraceni_naziv, ' - ', k2.skraceni_naziv) AS utakmica,
  u.datum_vrijeme,
  CONCAT(u.gol_domaci, ' : ', u.gol_gost) AS rezultat,
  ROUND(AVG(o.vrijednost), 2) AS prosjecna_ocjena_kluba
FROM klub k
JOIN igrac i ON i.klub_id = k.klub_id
JOIN statistika_igraca si ON si.igrac_id = i.igrac_id
JOIN ocjena o ON o.statistika_id = si.statistika_id
JOIN utakmica u ON u.utakmica_id = si.utakmica_id
JOIN klub k1 ON k1.klub_id = u.domaci_klub_id
JOIN klub k2 ON k2.klub_id = u.gostujuci_klub_id
GROUP BY k.klub_id, klub, utakmica, u.datum_vrijeme, rezultat
ORDER BY prosjecna_ocjena_kluba DESC
LIMIT 10;
```

klub	utakmica	datum_vrijeme	rezultat	prosjecna_ocjena_kluba
Dinamo	Rijeka - Varazdin	2024-08-12 19:00:00	0 : 0	9.80
Dinamo	Dinamo - Rijeka	2024-08-10 20:00:00	2 : 1	7.60
Hajduk	Hajduk - Osijek	2024-08-11 21:00:00	1 : 1	7.40
Osijek	Hajduk - Osijek	2024-08-11 21:00:00	1 : 1	7.20
Rijeka	Rijeka - Varazdin	2024-08-12 19:00:00	0 : 0	6.90
Rijeka	Dinamo - Rijeka	2024-08-10 20:00:00	2 : 1	6.75
Varazdin	Rijeka - Varazdin	2024-08-12 19:00:00	0 : 0	6.70

Slika 5 : prvi primjer složenog upita, autorski rad

2 . Primjer složenog upita koji uzima tablice *igrac*, *statistika_igraca* i *ocjena*, a kao rezultat upita vraća prosječnu ocjenu po poziciji igrača. Upit grupira sve nastupe prema poziciji te pomoću agregatne funkcije AVG računa prosječnu ocjenu za svaku poziciju. Uz to se prikazuje ukupan broj nastupa te broj različitih igrača po poziciji, uvjetu HAVING filtriraju se samo one pozicije koje imaju najmanje pet nastupa, dok se u liniji ORDER BY rezultati sortiraju prema prosječnoj ocjeni pozicije, od najbolje prema slabijima

```
SELECT
  i.pozicija,
  ROUND(AVG(o.vrijednost), 2) AS prosjecna_ocjena_pozicije,
  COUNT(*) AS ukupno_nastupa,
  COUNT(DISTINCT i.igrac_id) AS broj_igraca
FROM igrac i
JOIN statistika_igraca si ON si.igrac_id = i.igrac_id
JOIN ocjena o ON o.statistika_id = si.statistika_id
GROUP BY i.pozicija
HAVING COUNT(*) >= 5
ORDER BY prosjecna_ocjena_pozicije DESC;
```

Result Grid | Filter Rows: | Export: | Wrap Cell Content:

pozicija	prosjecna_ocjena_pozicije	ukupno_nastupa	broj_igraca
Napadač	7.92	5	4
Vezni	7.02	5	4
Golman	6.30	5	2
Obrambeni	6.30	5	2

Result 7 | Read Only

Output

Slika 6 : drugi primjer složenog upita, autorski rad

3 . Primjer složenog upita koji koristi tablice *igrac*, *statistika_igraca* i *ocjena*, a kao rezultat vraća listu igrača s njihovom prosječnom ocjenom i ukupnim brojem nastupa. Upit grupira podatke po igraču te pomoću agregatne funkcije AVG računa prosječnu ocjenu svakog igrača na temelju svih njegovih nastupa. Rezultati su sortirani prema prosječnoj ocjeni, čime se dobiva pregled najboljih igrača u ligi.

```
SELECT
  CONCAT(i.ime, ' ', i.prezime) AS igrac,
  ROUND(AVG(o.vrijednost), 2) AS prosjecna_ocjena,
  COUNT(*) AS broj_nastupa
FROM igrac i
JOIN statistika_igraca si ON si.igrac_id = i.igrac_id
JOIN ocjena o ON o.statistika_id = si.statistika_id
GROUP BY i.igrac_id, igrac
ORDER BY prosjecna_ocjena DESC
LIMIT 10;
```

Result Grid | Filter Rows: | Export: | Wrap Cell Content: | Fetch rows:

igrac	prosjecna_ocjena	broj_nastupa
Bruno Petković	7.41	9
Martin Baturina	7.09	8
Domagoj Bukvić	7.02	8
Ramón Miérez	6.98	8
Filip Krovinović	6.97	8
Leon Barišić	6.97	7
Gabriel Rukavina	6.95	8
Marko Livaja	6.94	8
Niko Janković	6.82	9
Matej Vuk	6.81	8

Slika 7 : treći primjer složenog upita, autorski rad

Okidači

Primjer 1

Početna funkcija

Prije samih prikaza triggera, pokazao bih početnu funkciju koja je nužna da bi logika triggera mogla raditi, unutar funckije izracunaj_ocjenu prvo za ulaz imamo razne statističke podatke koje vidimo na slici, nakon toga definiramo da želimo decimalnu vrijednost ocjene zaokružene na dvije decimale, početnu ocjenu postavljamo na 6,00 (većina aplikacija postavlja početnu ocjenu na 6,00 ili 6,5) i definiramo kako dajemo ocjenu, postoje pozitivne akcije kao što su odigrane minute, golovi, asistencije.. ali postoje i oni negativni kao što su prekršaji i kartoni (veće aplikacije imaju puno naprednije statistike kao na primjer skrivljeni golovi, netočna dodavanja.. ali za logiku ovog projekta smatram da je ovo dovoljno), za kraj onemogućavamo da ocjena ide ispod 0 ili preko 10.

```
DELIMITER $$
CREATE FUNCTION izracunaj_ocjenu(
    p_minute INT,
    p_golovi INT,
    p_asistencije INT,
    p_udarci_u_okvir INT,
    p_kljucna_dodavanja INT,
    p_uspjesni_driblinzi INT,
    p_prekrsaji INT,
    p_zuti INT,
    p_crveni INT
)
RETURNS DECIMAL(4,2)
DETERMINISTIC
BEGIN
    DECLARE ocjena DECIMAL(4,2);
    SET ocjena = 6.00;
    IF p_minute >= 60 THEN
        SET ocjena = ocjena + 0.30;
    ELSEIF p_minute >= 30 THEN
        SET ocjena = ocjena + 0.10;
    END IF;

```

Slika 8 : početna funkcija 1.dio, autorski rad

```
    SET ocjena = ocjena
        + (p_golovi * 1.20)
        + (p_asistencije * 0.90)
        + (p_udarci_u_okvir * 0.20)
        + (p_kljucna_dodavanja * 0.15)
        + (p_uspjesni_driblinzi * 0.10);

    SET ocjena = ocjena
        - (p_prekrsaji * 0.05)
        - (p_zuti * 0.30)
        - (p_crveni * 1.20);

    IF ocjena < 0 THEN
        SET ocjena = 0;
    ELSEIF ocjena > 10 THEN
        SET ocjena = 10;
    END IF;

    RETURN ROUND(ocjena, 2);
END$$

```

Slika 9 : početna funkcija 2.dio, autorski rad

Prvi trigger

trigger koji automatski izračunava ocjenu igrača

```
46 •  CREATE TRIGGER trg_ocjena_after_insert
47    AFTER INSERT ON statistika_igraca
48    FOR EACH ROW
49    BEGIN
50        DECLARE nova_ocjena DECIMAL(3,2);
51
52        SET nova_ocjena = izracunaj_ocjenu(
53            NEW.minute,
54            NEW.golovi,
55            NEW.asistencije,
56            NEW.udarci_u_okvir,
57            NEW.kljucna_dodavanja,
58            NEW.uspjesni_driblinzi,
59            NEW.prekrsaji,
60            NEW.zuti,
61            NEW.crveni
62        );
63
64        INSERT INTO ocjena (vrijednost, datum_izracuna, napomena, statistika_id)
65        VALUES (nova_ocjena, NOW(), 'Automatski izračun (INSERT statistike).', NEW.statistika_id);
66    END$$
67
```

Slika 10 : prvi okidač, autorski rad

Drugi primjer

trigger koji omogućava automatsku promjenu ocjene nakon sto se promijeni neki statistički podatak tijekom utakmice

```
70 •  CREATE TRIGGER trg_ocjena_after_update
71    AFTER UPDATE ON statistika_igraca
72    FOR EACH ROW
73    BEGIN
74        DECLARE nova_ocjena DECIMAL(3,2);
75
76        SET nova_ocjena = izracunaj_ocjenu(
77            NEW.minute,
78            NEW.golovi,
79            NEW.asistencije,
80            NEW.udarci_u_okvir,
81            NEW.kljucna_dodavanja,
82            NEW.uspjesni_driblinzi,
83            NEW.prekrsaji,
84            NEW.zuti,
85            NEW.crveni
86        );
87
88        UPDATE ocjena
89        SET vrijednost = nova_ocjena,
90            datum_izracuna = NOW(),
91            napomena = 'Automatski izračun (UPDATE statistike).'
92        WHERE statistika_id = NEW.statistika_id;
93    END$$
```

Slika 11 : drugi okidač, autorski rad

Prikaz funkcionalnosti razvijenog sučelja

Korisničko sučelje moje aplikacije je napravljeno na način da sam preko alata „visual studio“ ručno spojio svoju bazu podataka sa navedenim alatom i nakon toga sam uz pomoć HTML-a, CSS-a i Pythona (uz pomoć umjetne inteligencije) napravio korisničko sučelje za ovu aplikaciju. Pomoću korisničkog sučelja htio sam vizualno prikazati kako aplikacija radi, na početnoj stranici se vide igrači i podatci o njima. Moguće je putem gumba brisanje igrača iz baze podataka i uređivanje postojećih igrača, kao i dodavanje novog igrača. Kako je sučelje povezano s bazom podataka sve se automatski ažurira. Nakon bilo koje provedene uspješne operacije sustav korisniku vraća obavijest da je sve uspješno provedeno, a u slučaju greške vrati grešku i objasni u čemu je problem. Putem početne stranice moguće je otići na stranicu statistike igrača čija je ideja da korisnik može vidjeti detaljnu statistiku i ocjenu za igrača, ovdje su također implementirane CRUD operacije, a posebnost je što kod dodavanja statistike nije potrebno da korisnik sam unese ocjenu jer za to postoji trigger kojeg sam opisao u prošlom poglavlju. Korisnik unese sve statistike i ako je sve uspješno sustav mu javlja da je statistika dodana a ocjena se izračunala automatski, također ako korisnik želi izmijeniti neku statistiku ocjena se automatski ažurira, što je također već opisano ranije.

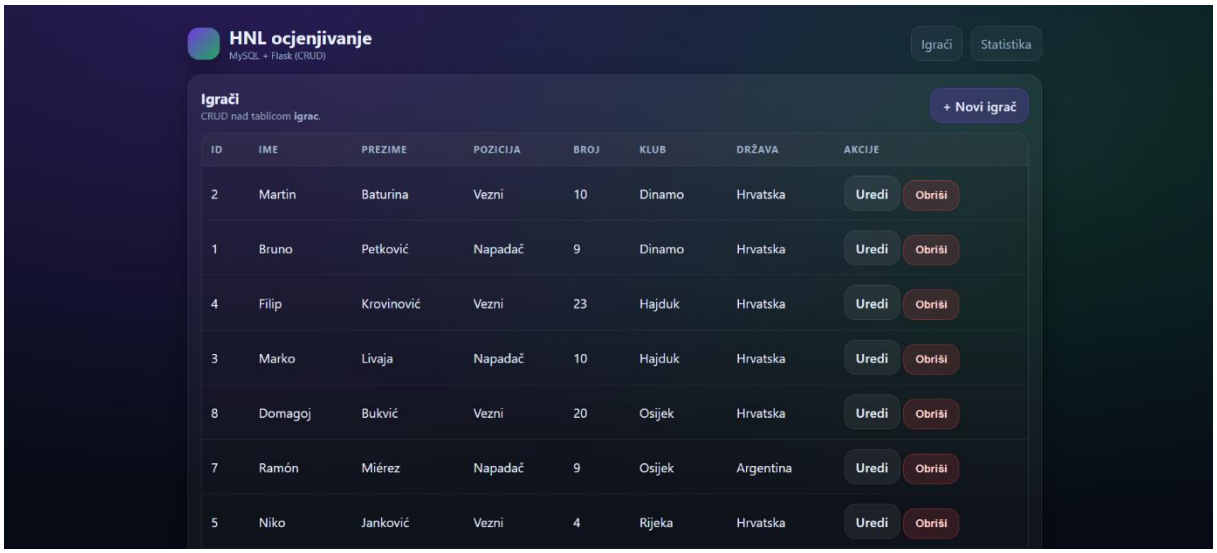

Slika 12 : početna strana sučelja s popisom igrača, autorski rad (uz primjenu umjetne inteligencije)

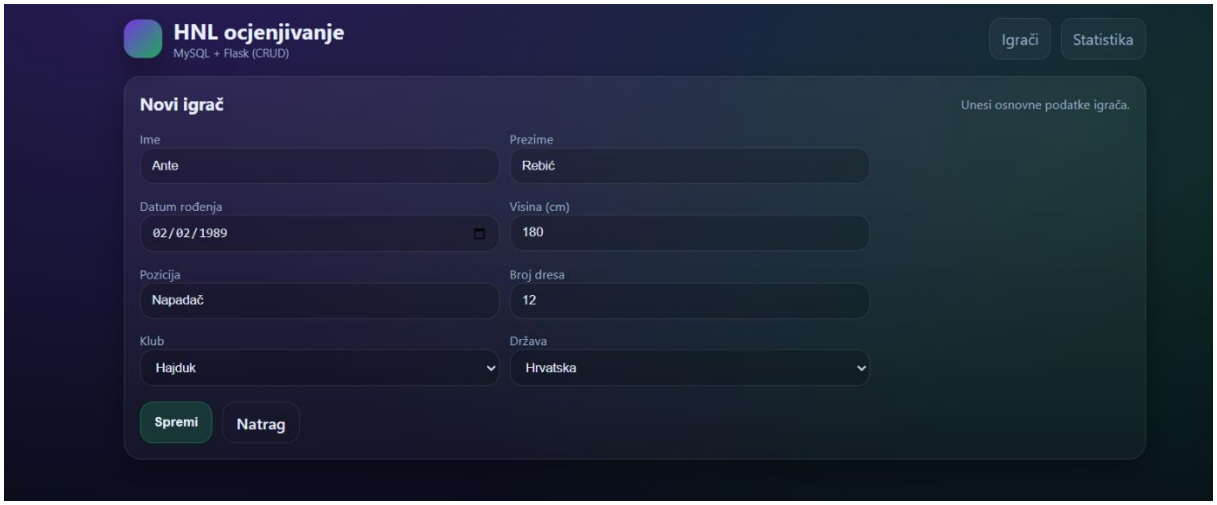

Slika 13 : unos novog igrača u aplikaciju, autorski rad (uz primjenu umjetne inteligencije)

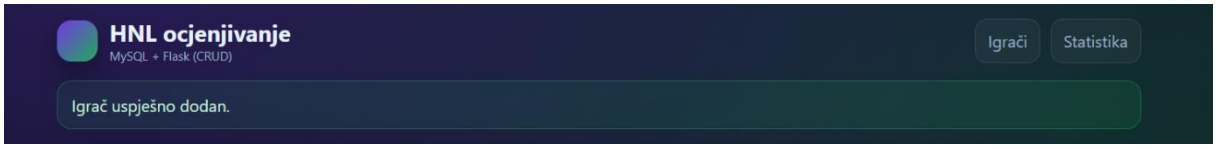

Slika 14 : obavijest aplikacije da je igrač uspješno dodan, autorski rad (uz primjenu umjetne inteligencije)

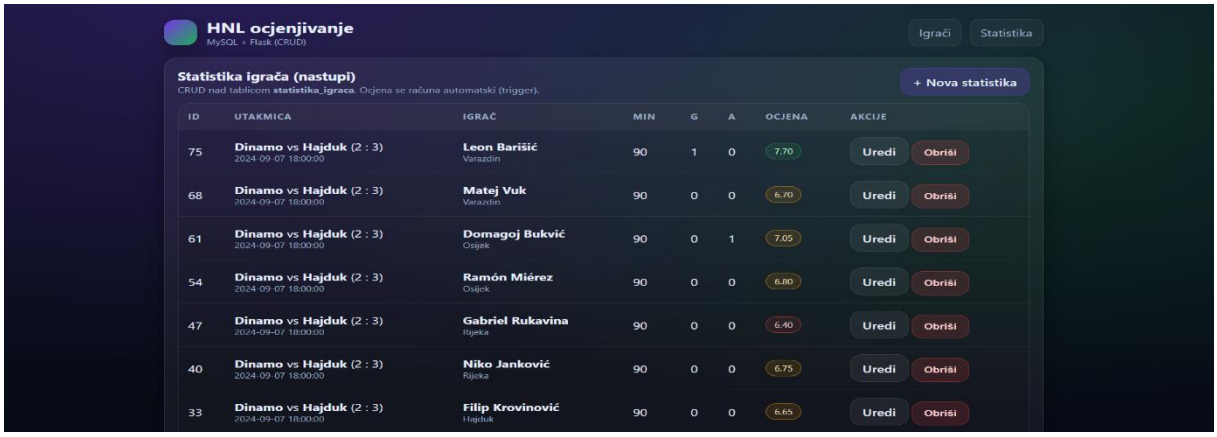

Slika 15 : prikaz sučelja statistike igrača, autorski rad (uz primjenu umjetne inteligencije)

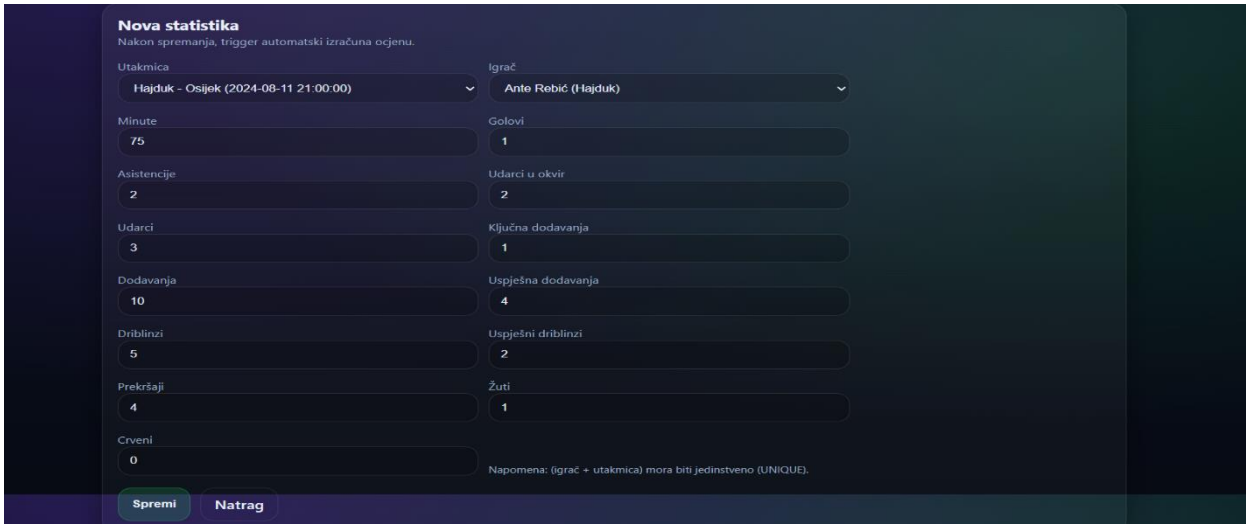

Slika 16 : prikaz načina na koji se dodaje nova statistika igrača unutar aplikacije, autorski rad (uz primjenu umjetne inteligencije)

Slika 17 : obavijest aplikacije o uspješno dodanoj statistici i o stvaranju ocjene automatski, autorski rad (uz primjenu umjetne inteligencije)

ZAKLJUČAK

U ovom projektu razvijen je cjelovit sustav za praćenje i ocjenjivanje igrača Hrvatske nogometne lige (HNL). Izrađen je entitetsko-relacijski (ERA) model koji detaljno opisuje domenu HNL-a, uključujući strukturu natjecanja (lige i sezone), klubove, utakmice, igrače, statističke pokazatelje i ocjene. Prema tom modelu implementirana je relacijska baza podataka u MySQL-u pomoću SQL naredbi. Razvijeni su brojni SQL upiti za dohvat i analizu podataka – od osnovnih SELECT naredbi do složenijih upita s JOIN-ovima, grupiranjem (GROUP BY) i agregatnim funkcijama. Time je demonstrirano kako se iz baze mogu dobiti korisne informacije, primjerice usporedba prosječnih ocjena igrača po klubovima ili rangiranje najboljih igrača prema određenim statističkim pokazateljima. Također su dodani okidači (triggeri) i pripadajuća funkcija za automatski izračun ocjene igrača na temelju unesenih statističkih podataka, što osigurava da se ocjene generiraju automatski i konzistentno, bez potrebe za ručnim unosom, čak i kada se statistički podaci naknadno mijenjaju. Uz sve to, razvijeno je i jednostavno grafičko korisničko sučelje u Pythonu (biblioteka Tkinter) koje korisnicima omogućuje intuitivno izvođenje CRUD operacija nad podacima, poput dodavanja novih igrača, ažuriranja statistike utakmice ili brisanja pogrešno unesenog podatka.

Provedbom svih ovih komponenti ostvaren je glavni cilj projekta – digitalno praćenje učinka igrača uz jednostavnije vođenje evidencije za trenere, sportske analitičare i klupsku administraciju. Centralizirano prikupljanje podataka o ligama, klubovima, utakmicama i pojedinačnim statističkim učincima, uz automatsko računanje ocjena, omogućuje bržu, točniju i objektivniju analizu performansi igrača. Takav sustav pomaže stručnom osoblju da lakše prate napredak igrača, uspoređuju njihove učinke unutar momčadi ili sezone te donose informiranije odluke, bilo u trenažnom procesu, selekciji igrača ili taktičkom planiranju. Sustav je pri tome osmišljen modularno i lako je proširiv, što ga čini čvrstom osnovom za buduća proširenja i nadogradnje. Ovim radom pokazano je kako digitalizacija procesa praćenja statistike može unaprijediti nogometnu analitiku te podići kvalitetu upravljanja sportskim podacima u HNL-u, što je posebno važno u suvremenom sportu koji se sve više oslanja na podatkovne analize.

Popis literature

M. Maleković, K. Rabuzin, Uvod u baze podataka, Varaždin: Fakultet organizacije i informatike, Sveučilište u Zagrebu, 2016.
K. Rabuzin, SQL – NAPREDNE TEME, Varaždin: Fakultet organizacije i informatike, Sveučilište u Zagrebu, 2014.
Oracle Corporation, *MySQL Community Server*. Pristupljeno kroz siječanj 2026., sa https://www.mysql.com/
Oracle Corporation, *MySQL Workbench*. Pristupljeno kroz siječanj 2026., sa https://www.mysql.com/products/workbench/

Popis slika

Slika 1 : ERA model, autorski rad....3
Slika 2 : prvi jednostavan upit, autorski rad 5
Slika 3 : drugi jednostavan upit, autorski rad 5
Slika 4 : treći jednostavan upit, autorski rad....6
Slika 5 : prvi primjer složenog upita, autorski rad 6
Slika 6 : drugi primjer složenog upita, autorski rad 7
Slika 7 : treći primjer složenog upita, autorski rad 7
Slika 8 : početna funkcija 1.dio, autorski rad....8
Slika 9 : početna funkcija 2.dio, autorski rad....8
Slika 10 : prvi okidač, autorski rad....9
Slika 11 : drugi okidač, autorski rad....9
Slika 12 : početna strana sučelja s popisom igrača, autorski rad (uz primjenu umjetne inteligencije)....10
Slika 13 : unos novog igrača u aplikaciju, autorski rad (uz primjenu umjetne inteligencije) ..10
Slika 14 : obavijest aplikacije da je igrač uspješno dodan, autorski rad (uz primjenu umjetne inteligencije)....11
Slika 15 : prikaz sučelja statistike igrača, autorski rad (uz primjenu umjetne inteligencije) ...11
Slika 16 : prikaz načina na koji se dodaje nova statistika igrača unutar aplikacije, autorski rad (uz primjenu umjetne inteligencije) 11
Slika 17 : obavijest aplikacije o uspješno dodanoj statistici i o stvaranju ocjene automatski, autorski rad (uz primjenu umjetne inteligencije) 11